

BicisBA

Facultad de Ingeniería, Universidad de Buenos Aires
[75.61] Taller de Programación III

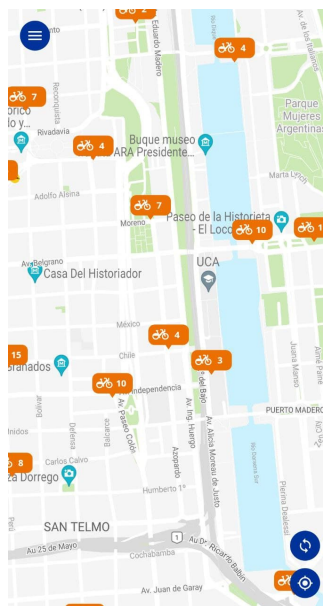
100029 del Mazo, Federico
94180 Lopez Destain, Francisco
98153 Mermet, Javier Ignacio

10 de Marzo de 2023

Bicis BA

Introducción

En 2019 la empresa brasilera Tembici ganó la licitación para operar el sistema de bicicletas compartidas de la ciudad de Buenos Aires, conocido como **EcoBici**, por 10 años. Los usuarios se deben registrar con tarjeta de crédito desde el sitio web para poder acceder al sistema. Luego, la aplicación **BA Ecobici** permite retirar bicicletas en cualquiera de las más de 200 estaciones repartidas en la ciudad.



Snapshot de la aplicacion

En la captura anterior de la aplicación podemos ver las estaciones cercanas a la sede en Paseo Colón de FIUBA. Se le indica al usuario la cantidad de bicicletas disponibles, y al hacer click, la cantidad de lugares disponibles para dejar una bicicleta, así quienes tengan que dejar una bicicleta tomada en otra estación saben si pueden dejarla ahí.

Sin embargo, esta información es una captura instantánea de las estaciones. Revisando la imagen anterior,

vemos que son pocas las estaciones cercanas a la facultad, sumando en su máxima capacidad menos de 100 bicicletas en conjunto. En los horarios donde materias de concurrencia masiva terminan en FIUBA, este número difícilmente alcance la potencial demanda, más aún considerando que difícilmente las estaciones están en su máxima capacidad. Entonces alguien que sale de cursar podría mirar la aplicación, ver que hay varias bicicletas disponibles, dirigirse hacia una estación y al llegar, encontrarse con que no hay más bicicletas, habiendo más gente que al salir de cursar haya hecho lo mismo. También podría generar dinámicas de subutilización del sistema: nadie intenta conseguir bicicleta porque asume que se va a repetir la situación anteriormente descripta.

La propuesta del presente proyecto es resolver el problema anteriormente descrito, aumentando las capacidades de la aplicación móvil BA Ecobici. Se plantea informar al usuario sobre cuál es la estación que mejores probabilidades de conseguir una bicicleta le otorguen. Complementariamente, informar sobre los tiempos de espera de cada estación.

Ciencia de datos

Descripción del problema

Cuando buscamos una bicicleta desde la aplicación tenemos distintas estaciones disponibles, pero debido al tiempo que nos toma llegar hasta el lugar pueden haber variado su estado desde que lo vimos en la app.

Para ayudar en la toma de decisiones proponemos dos modelos, basándonos en datos recolectados de la API de transporte de bicicletas. Un modelo que indique la probabilidad de encontrar una bicicleta disponible al llegar a las distintas estaciones disponibles. Un modelo que estima cuántos minutos faltan para que llegue la próxima bicicleta cuando la estación está vacía. ## Análisis exploratorio de datos ### Variables disponibles Las variables importantes que utilizamos en los modelos son:


- **last_reported** timestamp del momento en que se reportan los datos
- **station_id** identificador de las estaciones
- **num_bikes_available** número de bicicletas disponibles
- **num_bikes_disabled** número de bicicletas deshabilitadas
- **num_docks_available** número de espacios disponibles para estacionar
- **num_docks_disabled** número de espacios deshabilitados para estacionar

Promedios por estaciones

Tomando los datos de octubre del 2022 para todas las estaciones calculamos los promedios de cada una de las variables. Después analizamos sus valores agregados y distribuciones.

	var	min	max	mean	std
num_bikes_available		1.217	24.798	7.241	4.132
num_bikes_disabled		0.074	2.759	1.035	0.529
num_docks_available		1.173	25.907	9.689	4.885
num_docks_disabled		0.000	0.113	0.002	0.010
bikes_available		0.548	1.000	0.913	0.084


También se creó la variable `bikes_available` que calcula el porcentaje de tiempo que una estación tuvo al menos una bicicleta disponible. En promedio hay aproximadamente 7 bicicletas por estación, con bastante variación entre estaciones, y normalmente una deshabilitada. Se ve que casi nunca hay espacios para estacionar deshabilitados, y en promedio hay 9 espacios disponibles para estacionar. Finalmente el 91% del tiempo las estaciones tienen bicicletas disponibles, lo que nos dejan con cerca de un 9% del tiempo con estaciones vacías.



Distribucion de la media de las variables por estacion

Variación de bicicletas diarias


Tomando 5 estaciones al azar, vemos la disponibilidad de bicicletas promedio. Se puede ver que algunas estaciones tienen menos bicicletas disponibles en promedio, y que los máximos y mínimos se dan en momentos diferentes.



Cantidad de bicicletas promedio por hora para 5 estaciones tomadas al azar

Porcentaje de tiempo vacía


Tomando la primera semana de octubre se trajo el porcentaje de tiempo que la estación estuvo vacía por hora. Se puede ver que estaciones como la 188 siempre tiene bicicletas disponibles, mientras que la 174 pasa más tiempo vacía. También se ve que la disponibilidad baja en distintos momentos para las diferentes estaciones.



Porcentaje de tiempo que una estacion esta vacia por hora para 5 estaciones tomadas al azar

Evolución de bicicletas


Se armó un conjunto de datos con la cantidad de bicicletas disponibles después de diferentes periodos de tiempo. En el siguiente gráfico se compara la cantidad de bicicletas disponibles y la que quedaron después del periodo de tiempo, se puede ver una relación lineal con bastante variabilidad.



Distribucion de las bicicletas actuales vs las que quedan despues de distintos periodos de tiempo

Diferencia de bicicletas


A partir del conjunto de datos anterior se calculó la diferencia entre las bicicletas iniciales y las que quedaban en la estación, se puede ver que la diferencia de bicicletas se distribuye normalmente centrada en cero.



Distribucion de la diferencia de bicicletas despues de distintos periodos de tiempo

Diferencia de bicicletas en el tiempo

Se tomó el valor absoluto promedio de los cambios de bicicleta para distintos minutos desde el último reporte de la estación. Se ve que la diferencia de bicicletas crece mientras mas minutos pasan.



Evolucion del valor absoluto medio de diferencia de bicicletas en funcion del tiempo que pasa

Modelo de disponibilidad


Conjunto de datos

Para armar el conjunto de datos tomamos los siguientes estados reportados de cada estación, agregando los minutos pasados como característica y si hay bicicletas disponibles como valor a predecir. El resultado fue un dataset desbalanceado donde hay aproximadamente un 8% de valores negativos contra un 92% de valores positivos.

Métricas y modelos

Para analizar el desempeño de los modelos probados miramos la matriz de confusión. El peor escenario posible es recomendar una estación y que cuando el usuario llegue no haya bicicletas disponibles, entonces buscamos mantener una baja tasa de falsos positivos. Como eran muchos datos también se tuvo en cuenta el tamaño de los modelos y el tiempo de entrenamiento. La hora y el día de la semana se transformaron usando one hot encoding, donde fuese necesario, y las variables numéricas se estandarizaron. Se probaron redes neuronales,

random forest y lightgbm. El desempeño de los modelos era similar, pero por el tiempo de entrenamiento y mejora, elegimos lightgbm. Todos los modelos permiten agregar pesos a las muestras, de esta manera le damos más importancia a los casos negativos, para de esta manera reducir los falsos positivos.




Matriz de confusion para el modelo de disponibilidad

Conseguimos una tasa de falsos positivos de menos del 1%, con una precisión en la disponibilidad del 99.96%.

Estaciones como features vs estaciones como modelos


Las estaciones se pueden usar como features categóricas dentro de los modelos o tener modelos separados por cada estación. Usar las estaciones como features empeoraba los falsos negativos en un 50%, además de que el modelo tardaba 8 veces más en entrenar por la cantidad de datos, por eso decidimos usar las estaciones como modelos separados.



Matriz de confusion para el modelo de disponibilidad usando las estaciones como features

Shap values

Los Shap values permiten darle explicabilidad a los modelos complejos como light gbm. El valor medio de los shap values indica qué características están teniendo más importancia en el modelo para dar un resultado. Tomando los shap values sobre los modelos de 3 estaciones al azar, se puede ver que lo que más considera el modelo es la cantidad de bicicletas disponibles, junto con el momento de la consulta y el tiempo hasta la estacion.



Shap values para distintos modelos de disponibilidad de estaciones

Modelo de tiempo estimado de arribo

Conjunto de datos

Para armar el conjunto de datos tomamos el mínimo de los siguientes estados que tenían más bicicletas que el estado actual, cuando la estación está vacía, de ahí se obtuvieron los minutos hasta el próximo arribo que se tomó como el valor a predecir.

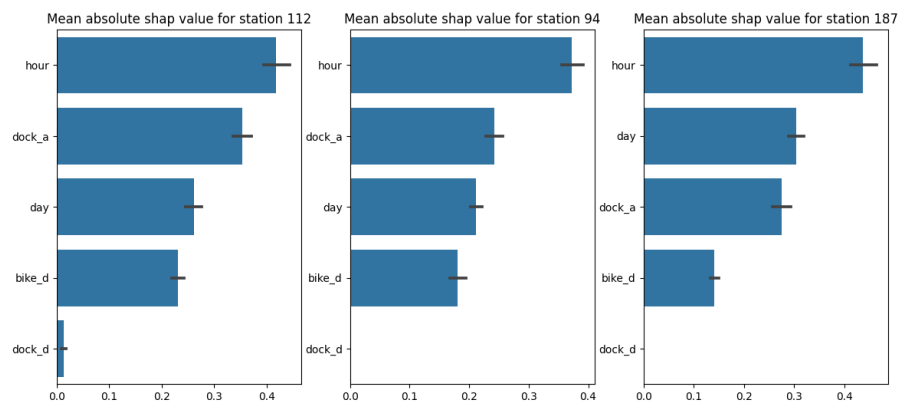
Modelos y métrica

Se usó el error absoluto medio para evaluar, de esta manera era fácil interpretar cuantos minutos de más podía hacer esperar a alguien el modelo. Al igual que en el modelo de disponibilidad se tuvo en cuenta el tamaño de los modelos y el tiempo de entrenamiento. Nuevamente la hora y el día de la semana se transformaron usando one hot encoding, y las variables numéricas se estandarizaron.

Probamos con redes neuronales, regresión lineal regularizada y lightgbm. El error medio absoluto de la regresión lineal era un poco peor que el de los otros dos modelos que llegaron alrededor de 4 minutos. Al igual que con el modelo de disponibilidad se eligió lightgbm por ser más rápido y eficiente en memoria en comparación con la red neuronal.

Shap values

Observando los shap values de modelos tomados al azar vemos que a lo que mas le prestan atención es a la hora, el día de la semana y los espacios disponibles.



Shap values para distintos modelos de tiempo de arribo de estaciones

Siguientes pasos

Ambos modelos pueden mejorarse teniendo en cuenta el estado de las estaciones cercanas. También se puede incorporar información sobre el estado global del sistema, teniendo en cuenta los viajes que se están realizando en este momento. Finalmente se puede incorporar información sobre trayectos frecuentes y modelar las dinámicas de los viajes. Además de la información del sistema de bicicletas en sí, se puede agregar al modelo datos que influyen en los patrones de comportamiento de los usuarios como el estado del clima y el tráfico. También se podrían considerar las fechas especiales, feriados o eventos de la ciudad.

Backend

Frontend

ipsum